


# 中国法学自主知识体系创新 人工智能辅助评价系统




上海交通大学人工智能研究院

金瀚阳

2026年6月



# 传统学术评价的“不可能三角”



## 标准不一

依赖专家主观经验，不同评审人尺度差异大，同一篇论文评价结论可能相差悬殊。

## 效率低下

评审周期漫长（数周到数月），专家调度成本高，难以快速响应大批量需求。

## 规模化难

面对近 10 年法学三大刊 **~1920 篇** 论文，人工逐一评审在现实中几乎不可行。



核心目标

构建面向“自主知识体系”的 AI 辅助学术评价系统

切入点

法学论文评审

**AI 定位：辅助初筛，不替代专家终审**

## ✓ AI 可以做

- 识别项目口径
- 生成六维信号
- 暴露模型分歧
- 整理评价证据

## ⚠ AI 不能做

- 裁定真正的首创性
- 替代主编最终判断
- 因政治正确性给高分

关键引用：v0.16 规程  
§1.2



# 评价对象与规模

可评测论文总量

1920 篇

元数据 1962 条，去重后可评测

数据源：近 10 年法学三大刊

《中国法学》《法学研究》

《中国社会科学》法学板块

## 刊物分布

《中国法学》

54 · 49.7%

《法学研究》

767 · 39.9%

《中国社会科学》

199 · 10.4%

## 当前评测进度

主评测 API 调用总量 ~94,700 次

全量评审

E1  
1920 篇

已生成 R1+R2，90 篇已补测

Top 60 重测 E2

50 篇

完整 R1+R2，交叉验证

第 3 次评测

E3  
13 篇

× 17 个不稳定维度

Top 30 验证


30 篇

信号 7.33–7.90，匹配 76 条



# 专家团队与样本体系

三级递进样本设计 严格防止调参集与验证集混用



## ⚠ 专家标注负样本 13 篇

每篇附专家逐维度书面意见，用于验证框架的负面识别能力。

正样本蒋红珍 91.1 分（未误伤）

有效识别 4 篇，正负差距 22.0 分

初始 3+ 补充  
10




# 四阶段评审流程





# 六维评价框架

三个递进层级 不是六个并列指标



## 命题与定位

研究创新性

30%

现状洞察度

20%

## 工具与论证

理论建构力

15%

逻辑连贯性

20%

## 风险与延展

学术共识度

10%

前瞻延展性

5%

关键设计原则——**不得倒置**：不因结论正确补救创新不足，不因涉及中国议题自动给高分。



# 概念操作化——把主观变客观

## 核心创新

将模糊的学术概念转化为可验证的检查清单，让 AI 有 " 尺子 " 可量，减少主观随意性

### 示例 1：枢纽

满足 4 项可检查标准中的  $\geq 2$  项

- ✓ 影响范围广  
涉及多个法律部门或制度领域
- ✓ 争议焦点  
学界存在持续争论或多种解释
- ✓ 理论基础  
涉及法学基本原理或核心概念
- ✓ 制度连锁  
解决方案会引发其他制度调整

### 示例 2：可争辩的法学问题

必须同时满足 4 项标准

- ✓ 有问题句  
明确提出疑问或待解决的理论问题
- ✓ 涉及法律规范  
与法律条文、判例或法理相关
- ✓ 有理论分歧  
存在不同学术观点或解释路径
- ✓ 非政策倡导  
不是单纯的政策宣传或价值倡导





## 多模型并发评审设计

每篇论文  $\times 6$  维度  $\times 4$  模型 = 24 次 API 调用

### A 组（宽松型）



GLM-5.1



Qwen3.6-Plus

### B 组（严格型）



DeepSeek-V4-Pro



Kimi-K2.6

### 为什么需要多模型？

单一模型存在系统性偏见，多模型并发暴露分歧  $\rightarrow$  交叉评审收敛  $\rightarrow$  提高可靠性

### 并发策略

论文级：3 篇并行

维度级：6 维度并行

模型级：4 模型并行



## 交叉评审机制（核心创新）

### Round 1：独立评分

4 个模型独立评分，互不可见

GLM

Qwen

DeepSeek

Kimi



### Round 2：交叉评审

#### A 组看 B 组的严格评价

GLM、Qwen 重新评

- 分
- accepted\_points：接受对方意见的理由
  - rejected\_points：拒绝对方意见的理由

#### B 组看 A 组的宽松评价

DeepSeek、Kimi 重新评

- 分
- accepted\_points：接受对方意见的理由
  - rejected\_points：拒绝对方意见的理由

### 设计哲学

- 不是取均值抹平差异，而是迫使模型审视自身偏见
  - DeepSeek 的“顽固性”是设计正确行为（锚定效应）
- 未收敛维度 = 真实学术分歧，交专家终审



# Autoresearch：与专家对齐 + 平衡模型差异


## 目的 1：与法学专家对齐

- 正样本不被误伤（蒋红珍 91.1 分）
- 负样本被有效识别（13 篇专家标注）
- 正负差距：22.0 分（有效识别的 4 篇）

## 目的 2：平衡模型间差异

- 降低多模型标准差，提高可靠性
- Kimi 评分系统性偏低（5/6 维度最低）
- GLM 与 Qwen 高度一致

迭代历程：v2.19 → v2.56.6（21+ 次迭代）



有效策略：放宽“部分满足”标准 + 增加【重要】提示 + 正面 / 反面锚点示例



## 可靠性验证与分层置信度

自动计算各维度均值、标准差 → 四级置信度分层 → 未收敛维度进入专家复核



### 核心原则

AI 评分与专家评分并列存储，不互相覆盖 → 专家终审权威高于 AI



## 自主知识体系信号校验

量化 0-8 分，用于候选分层，不计入基础分（基础分仍为六维 0-100）

### 四类核心信号

1

#### 中国问题中心性

以中国法律实践或制度为核心研究对象  
而非仅作为例证或背景

2

#### 中国实践解释尝试

尝试用理论框架解释中国法律现象  
而非仅描述或评价

3

#### 外部理论转化动作

对引入的外部理论进行本土化改造  
而非直接套用

4

#### 可复核概念或命题

提出可被学界检验的新概念或理论命题  
而非仅综述或评论

### 六类典型风险标记

政策复述

文化宣示

直接移植

制度介绍

价值倡导

纯粹比较



## 预检拒审与异常处理（Round 1 实际表现）

154 篇问题论文（占 1920 篇的 8.0%）

| 类别      | 数量   | 占比     | 说明                     | 处理策略     |
|---------|------|--------|------------------------|----------|
| 1- 空状态  | 90 篇 | 58.4%  | API/ 内容审查（Qwen 占 70 篇） | ✅ 已补测完成  |
| 2- 全部拒绝 | 5 篇  | 3.2%   | 4 模型一致排除（政策性论文）        | ✅ 可直接排除  |
| 3- 多数拒绝 | 19 篇 | 12.3 % | 2-3 模型拒绝，有分歧           | ⚠️ 需人工复核 |
| 4- 单一拒绝 | 15 篇 | 9.7%   | 1 模型拒绝                 | ⚠️ 需人工复核 |
| 5- 边界判断 | 25 篇 | 16.2 % | 项目口径边界，无拒绝             | ⚠️ 需人工确认 |

### 拒绝模型分布

Kimi-K2.6（33 次）> GLM-5.1（23 次）> DeepSeek-V4-Pro（15 次）> Qwen3.6-Plus（6 次）  
Kimi 最严格，Qwen 最宽松（与评分行为一致）



## 选择性第 3 次评测（方法论验证）

### 问题

Top 30 仍有 13 篇论文存在维度不稳定（ $\text{std} > 5$ ），是否需要全量第 3 次评测？

### 核心发现：六维度评分在数学上完全独立

- 每个维度由 4 模型独立打分  
prompt 不引用其他维度分数  
→ 维度间无交叉影响

- R2 交叉评审只看同维度  
其他模型的 R1 评分  
→ 不跨维度参考

- 总分 = 加权平均  
各维度互不影响  
→ 可选择性重测

### 选择性重测 vs 全量重测

#### 选择性方案（推荐）

13 篇异常论文 × 6 维度 = 78 个评分单  
仅 17 个维度不稳定（ $\text{std} > 5$ ）  
61 个稳定  
(78.2%)  
136 次 API 调用，节省 78%

#### 全量重测

13 篇 × 6 维度 × 4 模型  
= 312 次 API 调用  
包含 61 个已稳定维度  
边际收益 < 1 分

计分方式：三次 R2 均分取中位数（天然排除 outlier）



## 第 3 次评测收敛效果

13 篇 × 17 个不稳定维度，136 次 API 调用，总耗时仅 9 分钟（并发 5）

收敛率：17 个不稳定维度中 8 个收敛（std → ≤5）

| 论文               | 维度        | R3 R1 std | R3 R2 std | 收敛  |
|------------------|-----------|-----------|-----------|-----|
| 1023 法益修复与功能违法论  | 创新性       | 16.9      | 2.4       | ✓   |
| 1553 正当防卫中的退避义务  | 创新性       | 14.7      | 1.7       | ✓   |
| 1194 从基本权理论看法律行为 | 建构力       | 6.2       | 1.7       | ✓   |
| 956 公序良俗与诚实信用    | 延展性       | 15.6      | 3.6       | ✓   |
| 1501 改革型地方立法变通机制 | 创新性       | 12.7      | 8.3       | ✗   |
| 1885 论程序法上的犯罪事实  | 创新性       | 26.6      | 15.6      | ✗   |
| 1852 司法人工智能      | 创新性 + 洞察度 | 32.9/16.7 | 26.2/9.7  | ✗/✗ |

仍异常的 7 个维度（三次 std 仍 > 5）

需专家复核：1824 集体商标（建构力 14.0、洞察度 10.8）、1023 法益修复（创新性 9.9）

等





## 大规模评测进展概览

**E1 全量评审**

**1920**  
篇论文

已生成 R1+R2 结果文  
1913 篇完整评  
审

**E2 Top 60 重测**

**50**  
篇论文

完整  
验证 R1+R2  
排名稳定性

**E3 Top 30 第 3 次**

**13**  
篇论文

17 个不稳定维度  
选择性重测

### 评测时间线



### 关键指标


总评分单元: 1913 篇 × 6 维度 × 4 模型 × 2 轮 = **92,016 次**

**AI 评分**



# 交叉评审收敛效果

基于 11,520 个评分单元



整体标准差降幅

51.3%

R1 14.87 → R2 7.24



逻辑连贯性 R2 收敛率

93.2% 最高



研究创新性 R2 收敛率

44.8%

最低 · 真实学术分歧



# Top 30 最终排名（三次评测中位数）

计分方式：不稳定维度取三次 R2 均分的中位数，稳定维度取两次 R2 均分的均值

## Top 10 最终排名

| #  | 论文                 | 刊物     | 总分    | Δ3    |
|----|--------------------|--------|-------|-------|
| 1  | 公司决议瑕疵立法的范式转换与体系重构 | 法学研究   | 88.53 | —     |
| 2  | 法益修复与功能违法论         | 中国社会科学 | 88.13 | +1.02 |
| 3  | 代理公开的例外类型和效果       | 法学研究   | 87.98 | —     |
| 4  | 中国特色反腐败制度框架下贿赂犯罪法益 | 中国法学   | 87.88 | —     |
| 5  | 公序良俗原则与诚实信用原则的区分   | 中国社会科学 | 87.81 | +0.05 |
| 6  | 整体法秩序视野下被害人自陷风险    | 法学研究   | 87.75 | +0.33 |
| 7  | 论选择性要素的认识错误        | 法学研究   | 87.74 | —     |
| 8  | 民法典所有权保留之担保权构成     | 法学研究   | 87.73 | —     |
| 9  | 实体性查封优先权的理论证成及体系展开 | 法学研究   | 87.69 | —     |
| 10 | 债权人代位权的类型化构造       | 法学研究   | 87.56 | —     |

### 排名变化亮点

上升最多：1519 整体法秩序（↑ 10 位，#16→#6）；下降最多：1852 司法人工智能（↓ 16 位，#28→#44）



## Top 30 自主知识信号与知识库匹配

自主知识信号评测（2026-05-28）

DeepSeek-V4-Pro

7.33/8

Strong : 24 篇  
(80%)  
Medium : 6 篇  
(20%)

Qwen3.6-Plus

7.90/8

Strong : 29 篇  
(96.7%)  
Medium : 1 篇  
(3.3%)

两模型平均 std 0.28 ; 27 篇 std  $\leq 1.0$  , 23 篇完全一致

知识库匹配（中国法学自主知识体系树状知识库）

76

个知识条目  
均值 2.53  
条 / 篇

27

篇 high 置信  
3 篇  
medium

学科覆盖主轴

民法学 13 篇 · 刑法学 12 篇 · 法理学  
11 篇  
(多学科交叉计数)

Top 30 不只是 " 高分论文 " , 也具备强自主知识信号与明确知识谱系位置



## 模型行为差异与纠偏效果（亮点数据）

基于 1920 篇 × 6 维度 = 11,520 个评分单元的统计

### Round 1：两极对立

A 组（宽松型）

**91.5%**

包揽最高分

GLM 51.9% + Qwen 39.6%

B 组（严格型）

**94.9%**

包揽最低分

B 组最高分仅占  
8.5%

### Round 2：交叉评审后纠偏

B 组最高分占比

8.5% →

**62.2%**

A 组最低分占比

5.1% →


**34.9%**

模型间角色分工形成：B 组成为“挑刺者”，A 组成为“辩护者”



# 论文分数分布

1920 篇论文 R2 加权总分分布



均值  
**71.0**

中位数  
**74.5**

峰值区间  
**75-80** (23.5%)

标准差  
**12.1**

70-85 区间占比  
**60.0%**

R1→R2 均分变  
**71.1→71.0**

注：加权总分 = 创新性 ×30% + 洞察度 ×20% + 建构力 ×15% + 连贯性 ×20% + 共识度 ×10% + 延展性 ×5%



# 各模型评分特征画像

基于 1920 篇 R2 评分统计 ( 46,080 个模型 - 维度评分 )

| 模型              | 组别     | 均值   | std  | 最高分占比 | 最低分占比 | 特征        |
|-----------------|--------|------|------|-------|-------|-----------|
| DeepSeek-V4-Pro | B (严格) | 68.3 | 21.8 | 12.6% | 62.3% | 最严格，波动最大  |
| GLM-5.1         | A (宽松) | 71.5 | 17.1 | 8.6%  | 22.7% | 居中偏宽松     |
| Kimi-K2.6       | B (严格) | 73.2 | 13.4 | 22.2% | 13.0% | 居中，最稳定    |
| Qwen3.6-Plus    | A (宽松) | 75.1 | 15.6 | 56.6% | 2.0%  | 最宽松，最常给高分 |

## 关键发现

- 宽松 - 严格差距: Qwen ( 75.1 ) vs DeepSeek ( 68.3 ) = 6.8 分 系统性偏差
- R2 后 B 组最高分占比从 8.5% → 62.2% , 说明交叉评审迫使 B 组在认可时主动上调
- Kimi 最稳定 ( std=13.4 ) , DeepSeek 波动最大 ( std=21.8 )



# 框架迭代历程

v1.0 → v2.56.6 , 经历 56+ 版本迭代



## v2.56.6 核心成果

- 6 轮逐维度优化: AF → PO → LI → LC → CC
- ~~std 28.16~~ → 6.22 (降幅 **77.9%**)
- Holdout 验证通过 (无过拟合)


## v2.51 失败教训

- 短 prompt 无法判断论证质量
- AI 无法区分 "正常学术表述" 和 "空泛表述"
- Pattern 定义必须基于可观察指标





# 技术架构概览





# 失败经验与方法论沉淀

## v2.51 Phase 0 失败案例

### 问题诊断

- 负面模式检测器命中率 **22%** vs 目标 70%
- 误报率 **50%** vs 目标 10%
- Pattern 定义过于抽象
- AI 无法区分 "正常学术表述" 和 "空泛表述"

### 根本原因

短 prompt 无法提供足够上下文判断论证质量  
Pattern 依赖论证质量判断，而非可观察指标

### 决策

暂停 Phase 0，重新设计 pattern 定义

## 方法论沉淀

### 教训 1：Pattern 设计原则

- 必须基于可观察指标，避免依赖论证质量判断
- 可观察 = 可计数、可定位、可引用

### 教训 2：Autoresearch 策略

- 逐维度优化，6 轮迭代收敛
- 放宽 "部分满足" 标准，不降低高标准
- 增加【重要】提示 + 正面 / 反面锚点示例


### 教训 3：科学态度

公开记录失败，不隐藏负面结果  
失败是方法论迭代的必经之路



# 评测流程全景图

三层评测 + 一层解释验证体系





# | 核心成果总结

## 方法论创新

- ✓ 概念操作化：将模糊学术概念转化为可验证检查清单
- ✓ 四阶段流程：预检 → 六维评分 → 自主信号校验 → 评价层复核
- ✓ 交叉评审机制：R1 独立评分 → R2 交叉审视，std 降幅 51.3%

## 工程成果

- 1920 篇论文生成全量 R1+R2 结果 (E1)
- 50 篇完成 Top 60 重测 (E2)，std 降幅 56.5%
- 13 篇 × 17 维度完成选择性第 3 次评测 (E3)
- 30 篇 Top 候选完成自主信号评测  
平均信号强度 7.33-7.90/8，模型间 std 0.28
- 30 篇完成知识库匹配，76 个核验条目
- 主评测 API 调用总量 ~94,700 次
- 覆盖 11,520 个论文 - 维度评分单元

## 核心指标

R2 std 降幅  
**51.3%**  
(14.87 → 7.24)

Top 30 总分范围  
**85.77-88.53**  
均值 86.93

Top 30 刊物分布  
《法学研究》22 篇 (73.3%)、《中国法学》5 篇、  
《中国社会科学》3 篇



# I 局限与下一步

## 当前局限

### 1. 未收敛维度

- 7 个维度三次 std 仍  $> 5$  , 需专家终审
- 主要集中在研究创新性与理论建构力
- 1824 集体商标: 洞察度 std 10.8 、建构力 14.0

### 2. 预检问题论文待处理

- 34 篇 (多数 / 单一拒绝) 需人工复核
- 25 篇 (边界判断) 需确认项目口径
- 合计 59 篇待人工决策 (占 3.1% )

### 3. 研究创新性收敛率最低

- 收敛率 44.8% , 属真实学术分歧
- 如 " 论文是否提出可争辩理论问题 "

## 下一步工作

### 1. 专家复核流程

- 完整执行评价层复核流程
- 人工处理 59 篇预检问题论文
- 专家终审 7 个未收敛维度

### 2. 自主信号分歧处理

- 3 篇论文两模型 std=1.5
- 主要围绕 " 中国问题中心性 " 宽严判断
- 在专家说明中保留分歧解释

### 3. 拓展方向

- 从法学拓展至人文社科其他学科
- 完善知识库匹配与谱系定位



# | 致谢与讨论

## 致谢

感谢上海交通大学人工智能研究院的支持  
感谢特邀法学专家团队的指导与标注工作  
感谢项目团队成员的辛勤付出

## 开放讨论

欢迎提问与交流

联系方式: 金耀辉 · [jinyh@sjtu.edu.cn](mailto:jinyh@sjtu.edu.cn)

项目地址: [github.com/jinyh/SocialEval](https://github.com/jinyh/SocialEval)



## I 附录 A1：评分公式详解

六维加权基础分为总分主体，自主知识信号用于候选分层，不直接加分

### base\_score

= 创新性 × 30% + 洞察度 × 20% + 建构力 × 15% + 连贯性 × 20% + 共识度 × 10% + 延展性 × 5%

### 计分原则

1. 六维评分各自独立，避免互相补偿
2. 权重反映“命题与定位”的优先性
3. 总分只作为候选排序线索，不替代专家终审

### 信号层说明

final\_score = weighted\_sum ( 0–100 )

自主知识信号 = 0–8 分，进入证据包

二者交叉验证：高质量 + 强自主信号



## 附录 A2：典型论文评审报告示例

单篇报告由评分、证据、分歧和复核建议四部分构成

### 论文信息

题名：示例高分候选论文  
刊物：法学研究 / 中国法学  
年份：近十年样本

输出内容：

六维均分与标准差  
模型 `accepted / rejected points`  
自主知识信号证据

### 六维评分快照

研究创新性：88.5 / std 4.2



理论建构力：86.0 / std 5.1



逻辑连贯性：90.2 / std 3.0



报告保留模型差异，不只给单一均值

### 专家复核入口

触发条件：任一维度  $\text{std} > 8$

复核材料：原文证据 + 模型分歧

处理方式：专家评分并列存储

目标：让专家看见“为什么分歧”  
而不是只看一个难以解释的总分





## 附录 A3：各维度收敛率详细分析

客观性越强，模型越容易收敛；高阶创新判断保留专家空间

### 高收敛维度

逻辑连贯性： 93.2%




原因：文本内部一致性、论证断裂、概念混用等线索较可观察。

前瞻延展性：



### 低收敛维度

研究创新性： 44.8%



原因：是否“真正提出可争辩理论问题”本身存在学术判断差异。

理论建构力： 56.0%



结论：不把所有分歧压成均值，未收敛维度进入专家终审



## I 附录 A4：与人工评审的对比

AI 辅助系统解决规模化初筛问题，专家保留最终学术裁断

### 传统人工评审

优势：学术经验深、能判断真实首创性

限制：周期长、尺度差异大、难以覆盖 1920 篇

适合承担：终审、价值判断、争议裁断

### AI 辅助评价

优势：可规模化、可复现、能暴露模型分歧

限制：不替代专家判断，不裁定真正首创性

适合承担：初筛、证据整理、分歧定位

推荐机制：AI 初筛 + 专家终审，评分与专家意见并列留痕



## I 附录 A5：补充负样本专家意见摘录

负样本用于验证框架是否能识别“形式合规但学术贡献不足”的论文

### 意见类型一：洞察不足

“仅罗列现象，未揭示制度逻辑”

对应维度：现状洞察度

AI 处理：要求定位问题背后的规范结构

### 意见类型二：框架不足

“分析框架缺乏可操作性”

对应维度：理论建构力

AI 处理：检查概念、命题、推理链是否可复核

### 意见类型三：结论先行

“政策宣示替代学术论证”

对应维度：学术共识度 / 预检口径

AI 处理：区分政策阐释与法学研究

验证结果：正样本不被误伤，部分负样本被有效拉开分差

v2.50.2：有效识别负样本与正样本差距约 22 分



# 附录 A6：选择性第 3 次评测详细数据

13 篇论文 × 17 个不稳定维度 = 136 次 API 调用（vs 全量 624 次，节省 78%）

收敛维度（std ≤ 5）

8/17

47.1 %

进入可接受范围（std ≤ 8）

10/17

58.8%

仍需专家终审（std > 8）

7/17

41.2 %

| 维度    | E1 R2 均分 | E2 R2 均分 | E3 R2 均分 | E3 std | 状态  |
|-------|----------|----------|----------|--------|-----|
| 研究创新性 | 85.2     | 84.8     | 85.0     | 9.2    | 未收敛 |
| 现状洞察度 | 82.5     | 83.1     | 82.8     | 4.2    | 已收敛 |
| 理论建构力 | 80.3     | 79.8     | 80.1     | 10.5   | 未收敛 |
| 逻辑连贯性 | 88.7     | 89.2     | 88.9     | 3.1    | 已收敛 |
| 学术共识度 | 86.4     | 87.0     | 86.7     | 6.8    | 可接受 |
| 前瞻延展性 | 84.1     | 83.8     | 84.0     | 4.5    | 已收敛 |

注：完整 17 个维度数据见 [results/retest-top60/top30\\_anomaly\\_check.md](#)



# 附录 A7：Top 30 三次评测排名对比

排名变化 ≥ 5 位的论文详细分析

## 关键发现

- 中位数 vs 均值排名差异：3 篇论文排名变化 ≥ 5 位
- 新进入 Top 30：2 篇（E3 后上升）
- 跌出 Top 30：2 篇（E3 后下降）

## 主要变化原因

- 研究创新性维度第 3 次评测分歧收敛
- 理论建构力维度模型间分歧加剧
- 中位数对极端值的鲁棒性优于均值

| 论文编号 | E1 排名 | E2 排名 | E3 最终排名 | 排名变化 | 主要原因  |
|------|-------|-------|---------|------|-------|
| 010  | 1     | 1     | 1       | 0    | 稳定    |
| 0820 | 3     | 2     | 2       | +    | 微调    |
| 1023 | 1     | 8     | 5       | +7   | 创新性收敛 |
| 1824 | 1     | 22    | 28      | -10  | 建构力分歧 |
| 1307 | 32    | 3     | 29      | +3   | 新进入   |
| 0956 | 28    | 29    | 31      | -3   | 跌出    |

注：完整 30 篇排名对比见 [results/retest-top60/top30\\_comparison.md](#)



# 附录 A8：Round 1 问题论文详细分析

154 篇问题论文分类（占 1920 篇的 8.0%）

| 类别      | 数量   | 已处理   | 待处理     | 说明        |
|---------|------|-------|---------|-----------|
| 1- 空状态  | 90 篇 | ✓ 已补测 | —       | API/ 内容审查 |
| 2- 全部拒绝 | 5 篇  | ✓ 已排除 | —       | 政策性文本     |
| 3- 多数拒绝 | 19 篇 | —     | ⚠ 需人工复核 | 2-3 模型拒绝  |
| 4- 单一拒绝 | 15 篇 | —     | ⚠ 需人工复核 | 1 模型拒绝    |
| 5- 边界判断 | 25 篇 | —     | ⚠ 需人工确认 | 口径归属      |

## 模型拒绝行为画像（1920 篇统计）

| 模型              | 组别    | 拒绝次数 | 拒绝率 | 评分均值 | 行为特征       |
|-----------------|-------|------|-----|------|------------|
| Kimi-K2.6       | B（严格） | 33 次 | 最严格 | 73.2 | 拒绝与评分一致    |
| GLM-5.1         | A（宽松） | 23 次 | 偏严格 | 71.5 | 拒绝多但评分宽松   |
| DeepSeek-V4-Pro | B（严格） | 15 次 | 中等  | 68.3 | 评分最严但拒绝适中  |
| Qwen3.6-Plus    | A（宽松） | 6 次  | 最宽松 | 75.1 | 拒绝最少，评分最宽松 |



## 附录 A9：Top 30 自主信号与知识库匹配详细数据

### 自主知识信号评测（30 篇 × 2 模型）

#### DeepSeek 评测结果

- 平均信号强度： **7.33/8**
- Strong 信号： 24 篇（80.0%）
- Moderate 信号： 6 篇（20.0%）
- 典型案例： 0101 中国特色反腐败制度框架

#### Qwen 评测结果

- 平均信号强度： **7.90/8**
- Strong 信号： 29 篇（96.7%）
- Moderate 信号： 1 篇（3.3%）
- 模型间平均 std： **0.28**

### 知识库匹配成果

#### 匹配统计

- 总匹配条目： **76**
- LLM verified： 76 个
- High 置信度： 27 篇
- Medium 置信度： 3 篇
- 学科覆盖：民法、刑法、  
法理学为主轴

#### 匹配类型

- 标识性概念： 32 个
- 原创性理论： 18
- 框架结构： 26 个
- 典型案例：  
0101 贿赂犯罪法  
0820 法律行为理论

#### 分歧案例

- 3 篇论文两模型 std=1.5
- 主要围绕“中国问题  
中心性”宽严判断
- 案例： 0820、1307、  
1821
- 处理：在专家说明中  
保留分歧解释