专家征询版

法学论文 AI 辅助评审逻辑与流程复盘

面向专家意见征询与机制共建

这不是某个版本的发布说明，而是一套正在收敛中的法学评审机制复盘。

目标是请专家帮助校准规则、指出边界、支持后续试点推进。

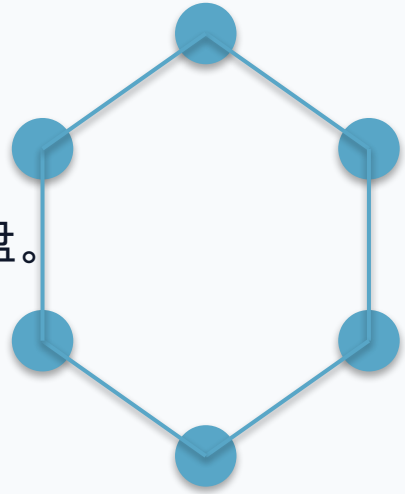

评审标准显化

判断链条可复核

邀请专家参与校准

传统评审的难点不只在效率，更在标准难显化

专家判断高度依赖隐性经验，难以直接迁移给 AI

三个真正的结构性难点

关键难点

标准隐含于共同体经验

很多判断依赖共同体默认知识，不总能直接写成规则。

关键难点

解释过程难复用

同样的判断理由难以沉淀为可复核、可迁移的稳定过程。

关键难点

AI 只能模仿语言，不能自动模仿判断

如果不先外化标准，模型容易生成像评审的话，却未必真的按评审逻辑判断。

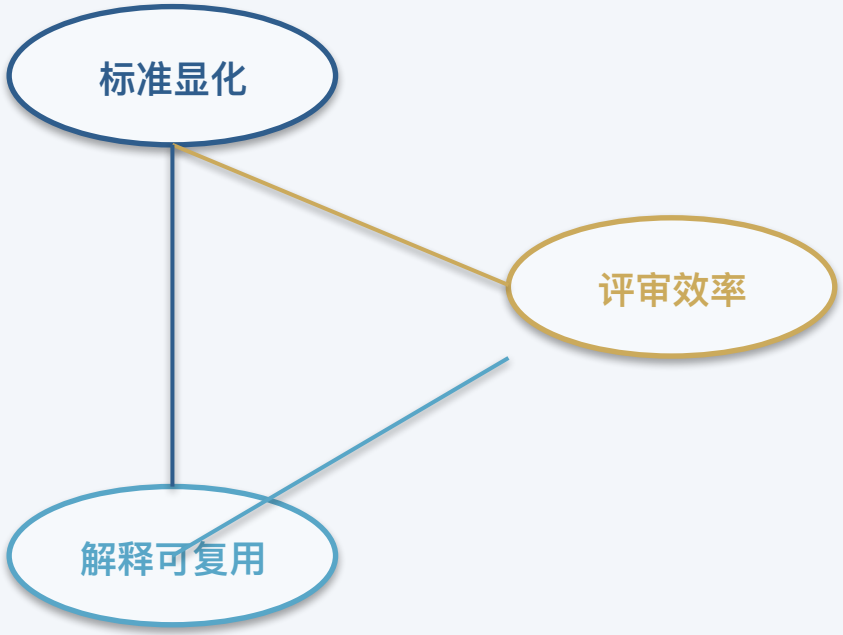

判断困难的核心不是工作量，而是专家标准长期以隐性知识形式存在。

当前主链路把论文评审拆成可复核的七个环节

从论文输入到报告输出，每一步都对应明确的判断任务

01 文档预处理

02 前置检查

03 六维评分

04 可靠性判断

05 报告生成

06 专家复核接口

07 版本留存

规则驱动　模型输出　人工介入

- 主链路依据当前配置、需求文档与代码实现整理。
- 目标不是自动定结论，而是拆解判断节点。

主链路依据：当前 YAML 配置、需求文档 v0.4 、评审主流程代码。

AI 常常听懂了词面，却没有准确对齐评审意图

同样的评审要求，不同模型并不会自动进入同一个法学语境

专家评审意图

- 创新性如何定义
- 洞察度何为充分
- 可接受性边界在哪

YAML 规则层

定义	顺序	上限
证据	输出	复核

模型 A
输出解释并不天然一致

模型 B
输出解释并不天然一致

模型 C
输出解释并不天然一致

规则必须从“隐含理解”转成“显式控制”，否则输出会随模型和时间漂移。

YAML 不是“参数表”，而是评审机制真正的规则层

它把专家经验从隐含判断变成可加载、可执行、可修改的规则集合

它不是只写六维和权重

- 还会写 precheck 。
- 还会写评分锚定与封顶规则。
- 还会写输出格式与复核标记。

YAML 规则层

- precheck
- decision_order
- scoring_criteria
- ceiling_rules
- output_contract
- review_flags

从专家视角看，它就是把评审经验写成一套可审阅、可修改、可追踪的规则接口。

接下来三页分别解释

- 它先定义“评什么”。
- 再定义“怎么判”。
- 最后定义“怎么输出与复核”。

这页的作用：先把 YAML 从“技术细节”提升为“机制中心”。

YAML 先定义“评什么”，并规定判断顺序

先把评价对象和程序写清，模型才不会直接跳到结论

这一层写入的对象

precheck	决定是否进入六维评分
dimensions	定义六维结构
weight	定义总分计算关系
decision_order	规定先看什么后看什么

运行时的对应作用

- 先跑 precheck，判断论文是 pass、conditional_pass，还是 reject。
- 再按 dimensions 逐维评分，而不是让模型一次性凭整体印象给总分。
- 最后按 weight 计算综合得分，并保留每个维度独立判断。
- decision_order 强制模型按固定程序判断，避免跳步和偷看结论。

这一层控制的是：评价对象和评价程序。

YAML 再定义“怎么判”，也就是锚定区间与封顶边界

真正影响分数稳定性的，不只是 prompt，而是 scoring_criteria 和 ceiling_rules

评分锚定是怎么工作的

excellent	高位区间，要求关键条件基本成立
good	条件成立但强度有限
marginal	勉强成立，问题明显
unacceptable	基础条件不成立

封顶和边界为什么重要

- ceiling_rules 决定：哪些基础条件不成立时，分数必须封顶。
- 它防止模型在“问题并未成立”或“研究地图明显残缺”时仍然给出高分。
- boundary_notes 会提醒：本维度评什么、不评什么，减少维度串位。
- 这一步控制的是：分档依据和封顶边界。

这页解释的是：为什么真正左右分数稳定性的，往往是规则而不是语言润色。

YAML 最后定义“怎么输出”以及“何时提示复核”

结果不仅要能生成，还要能被比较、核验和人工接手

结果生成前

- prompt_template 决定模型按什么路径进入该维度。
- 它会把本维度的定义、判断步骤、字数限制、输出格式要求一起带进去。

结果生成时

- output_contract 约束必须返回哪些字段。
- 缺字段、乱字段、分数不服从规则，都应该视为失败输出。

结果生成后

- review_flags 把证据不足、边界模糊、需要外部核验等情况显式标出。
- 这样专家不是接手一团文本，而是接手一个已标注风险点的结构化结果。

这一层控制的是：结果是否可读、可比、可复核，以及何时应提醒人工接手。

六维框架把法学论文的判断链条外化出来

从起点到落脚，六个维度共同构成结构化评价路径

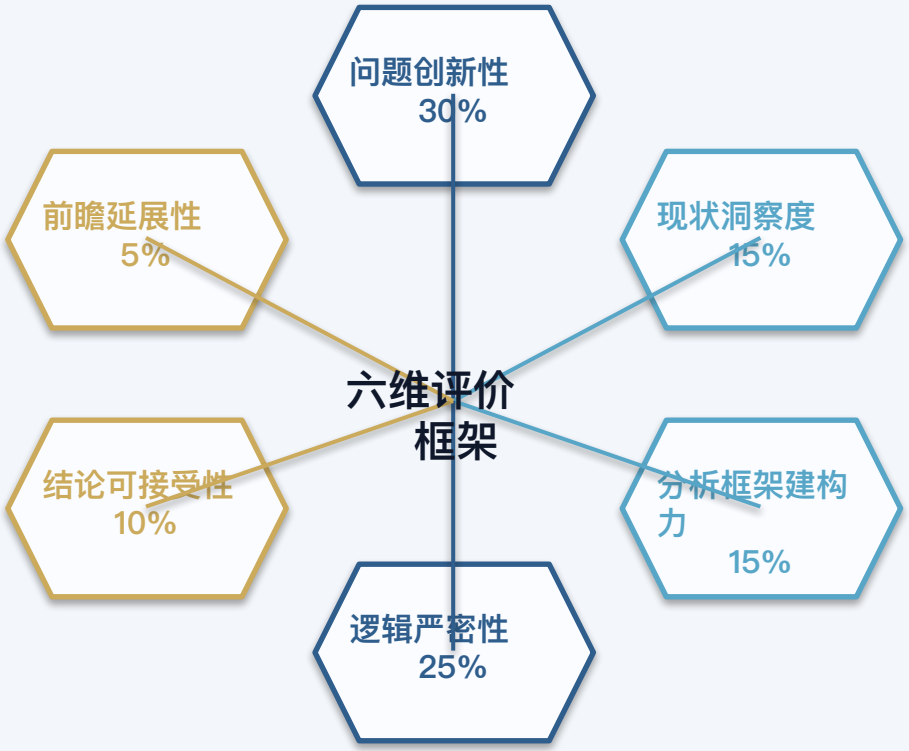

判断链条

- 起点 — 问题创新性
- 定位 — 现状洞察度
- 工具 — 分析框架建构力
- 骨架 — 逻辑严密性
- 落脚 — 结论可接受性
- 开放 — 前瞻延展性

权重来自当前法学配置，六维共同构成完整评价路径。

这套机制不是一次成型，而是沿着四条方向持续收敛

关键不是追版本，而是让评审尺度越来越可解释、可校准、可复核

持续收敛

概念清单化

把模糊概念改成检查清单，减少凭感觉打分。

关键维度操作化

研究地图、分析框架、结论可接受性、前瞻延展性逐步细化。

封顶规则收窄

持续收窄 ceiling rules 触发条件，避免轻易封顶。

输出结构收短

让输出更短、更结构化，更利于专家快速核验。

单维评分必须先抽证据，再分档给分

固定顺序把印象打分改成证据驱动判断

01
定位评价对象

02
抽取关键证据

03
判断上限规则

04
确定分档给分

05
输出摘要与理由

原则：禁止先凭整体印象给分，必须先定位对象、抽证据、判规则，再进入分档与分数。

统一输出契约让 AI 的判断可解释、可比较、可复核

关键不是只给分，而是留下可供专家审核的判断结构

输出字段示意

- score / band
- summary / core_judgment
- score_rationale
- evidence_quotes
- strengths / weaknesses
- review_flags

为什么要严格统一

可解释 专家能看到 AI 为什么这么判。

可比较 不同模型可以横向比较。

可复核 事后可回看证据与规则。

可靠性判断决定哪里可以采纳，哪里必须请人介入

重点不是谁分高，而是分歧有多大、结论可采纳到什么程度

模型得分示意

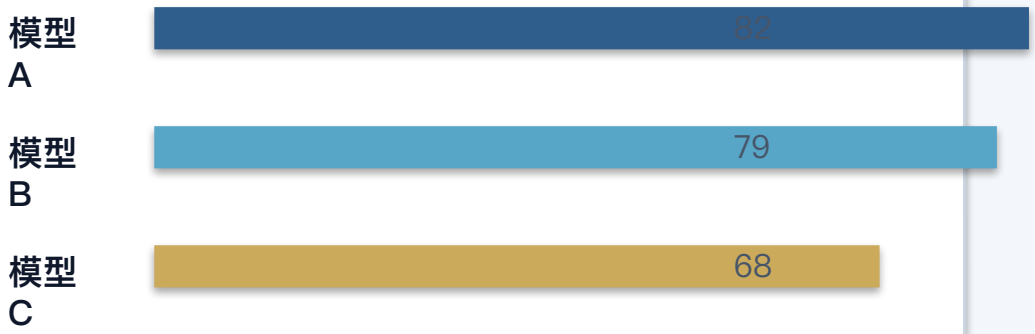

均值 76.3

std 7.4

进入复核

判断意义

- 高置信度不等于无需专家，低置信度更明确提示必须复核。
- 这一层把“模型输出”转成“可采纳程度判断”。
- 当前阈值讨论本身也需要专家共同校准。

当前边界仍然清楚存在，这正是专家意见最有价值的地方

机制可以运作，但可信边界仍要靠共同体继续校准

已结构化部分

维度定义 / 决策顺序 / 输出契约

仍需专家判断部分

维度边界 / 流派识别 / 证据充分性 / 封顶规则

专家最值得发力的地方

- 哪些维度边界仍然模糊，需要更精确地切开。
- 哪些规则触发过宽、过窄，导致 AI 失真或过度保守。
- 哪些概念仍然过于抽象，尚未真正进入法学共同体语境。

下一步分两段推进：1 个月校准，半年形成稳定机制

目标不是更快自动化，而是把可用机制推进到可信机制

未来 1 个月

收集反馈 → 校准规则 → 补样本 → 打磨复核

核心目标：先把规则争议点暴露出来，让专家意见真正进入机制。

未来半年

稳定规则 → 标准样本库 → 人机协同 → 制度接入

核心目标：形成更稳定的规则体系、样本体系和复核流程，再讨论跨学科扩展。

希望专家帮助我们把机制从可用推进到可信

校准六维逻辑与边界规则

参与样本试评与阶段性评估

支持共建与试点推进

如果这套方向成立，我们希望下一步不是“证明 AI 能替代评审”，而是与专家一起把评审标准做得更清楚、更可信。

期待专家对机制逻辑、规则边界、样本校准与试点路径提出意见。